Fundamentos de Segurança Informática (FSI)

2021/2022 - LEIC

Manuel Barbosa mbb@fc.up.pt

Aula 6 Controlo: Defesas

Relembrar os ataques

- Stack smashing: reescrever o endereço de retorno na stack para código malicioso
- Heap spraying: evitar ter de prever o endereço exato do código malicioso, criando muitas cópias em memória
- Use after free: aproveitar que programa está a utilizar memória que está já fora do seu controlo para modificar essa memória antes da utilização incorreta
- Format string vulnerabilities: uso de strings de formatação criadas pelo adversário
- Integer overflows: erros em cálculos que levam, por exemplo, a alocação de memória insuficiente para a utilização

•

O que há de comum

- Os dados, potencialmente provenientes de fora do círculo de confiança, podem interferir com o controlo do programa
- Por exemplo: buffer de dados armazenado na stack ao lado do endereço de retorno
- A falta de separação entre dados e controlo é um problema recorrente:
 - mais à frente vamos ver isto novamente em XSS na segurança Web
- Mesmo quando os princípios de gestão de memória são corretos, os erros de implementação podem deitar tudo a perder

Defesa em profundidade

- Minimizar a probabilidade de erros na gestão de memória
 - Usar linguagens de programação que garantem memory safety (Java, Go, Rust, etc.), ou
 - Verificar que os programas estão corretos (mais esforço, mas a única hipótese para código legacy)
- Medidas de proteção na própria plataforma: impedir a execução de código malicioso
- Medidas de proteção no executável: detectar tentativa de highjacking
 - monitorização do estado da stack, tagging de memória, etc.

controlo passa a DoS

Mitigações na Plataforma

Data Execution Prevention

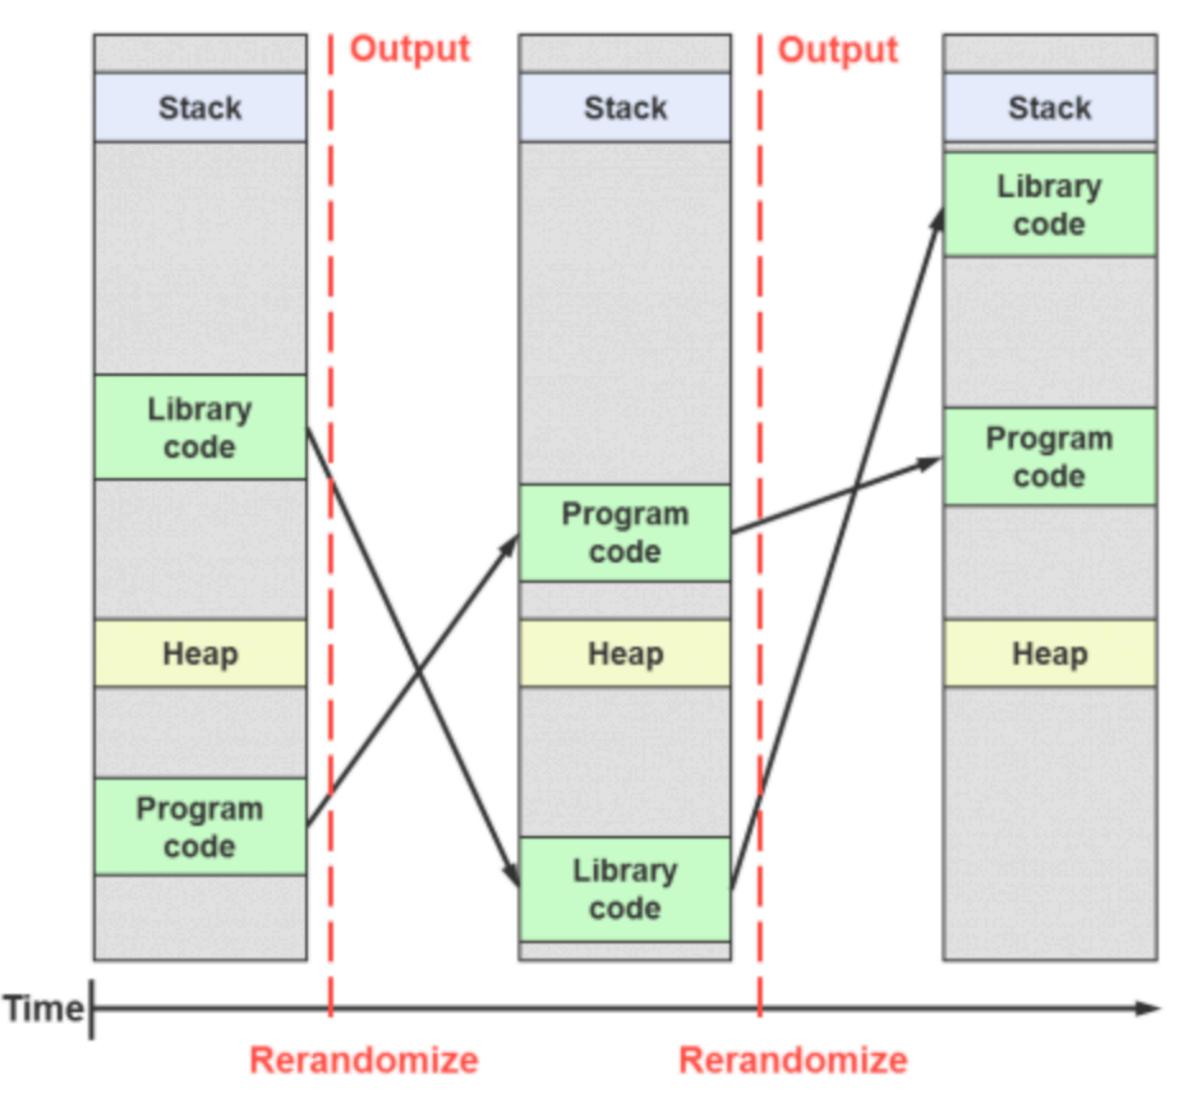
- Também chamada Executable Space Protection, referida anteriormente:
 - motivação para Return Oriented Programming
- A memória nunca pode ser simultaneamente:
 - passível de ser escrita por um programa
 - passível de conter código executável
- Pode ser implementada em hardware (NX bit) ou emulada em SW

Data Execution Prevention

- As arquiteturas mais populares oferecem suporte em hardware:
 - AMD, Intel, ARM: permitem desativar execução ao nível da página
- Implementado pelos sistemas operativos mais utilizados desde meados dos anos 200X
- Limitações:
 - só por si não evita exploits que reutilizem código, tal como ROP
 - cria problemas em cenários de Just-in-Time compilation (e.g., nos browsers para correr código do lado do Cliente)

Address Space Layout Randomization

- A localização de código e dados em memória é gerada de forma aleatória em cada execução:
 - stack, heap, bibliotecas partilhadas, código de base
- Vantagens: atacante n\u00e3o consegue prever os endere\u00e7os de c\u00f3digo \u00e9til (ROP)
- Utilizações:
 - sistemas operativos mais populares desde meados dos anos 200X
 - cada vez maior entropia para tornar previsão mais difícil (primeiro 8 bits, depois 24 bits)



Address Space Layout Randomization

- O que pode fazer um atacante:
 - outras vulnerabilidades fornecem informação sobre endereços (e.g. format strings)
 - tentar muitas localizações (heap spraying) sem crashar o programa
 - utilizar código do sistema operativo (kernel)?
- Proteção também aplicada ao endereço do Kernel (KASLR):
 - problema: apenas muda de boot para boot
 - problema: sabendo a base do kernel, podem prever-se outros endereços
 - solução: Kernel Address Randomized Link (KARL) o próprio código do kernel é "baralhado"



A new feature added in test snapshots for OpenBSD releases will create a unique kernel every time an OpenBSD user reboots or upgrades his computer.

This feature is named KARL — Kernel Address Randomized Link — and works by relinking internal kernel files in a random order so that it generates a unique kernel binary blob every time.

Mitigações no Executável

Deteção em Tempo de Execução

- Um segundo nível de proteção:
 - o compilador adiciona código que permite detectar um potencial ataque
 - transforma exploits que permitem excecução arbitrária de código em ataques DoS porque a execução do programa termina
- De uma forma mais geral pode falar-se de "run-time monitoring":
 - uma técnica de verificação que executa código adicional para "vigiar" código mais complexo que está a desempenhar a funcionalidade pretendida

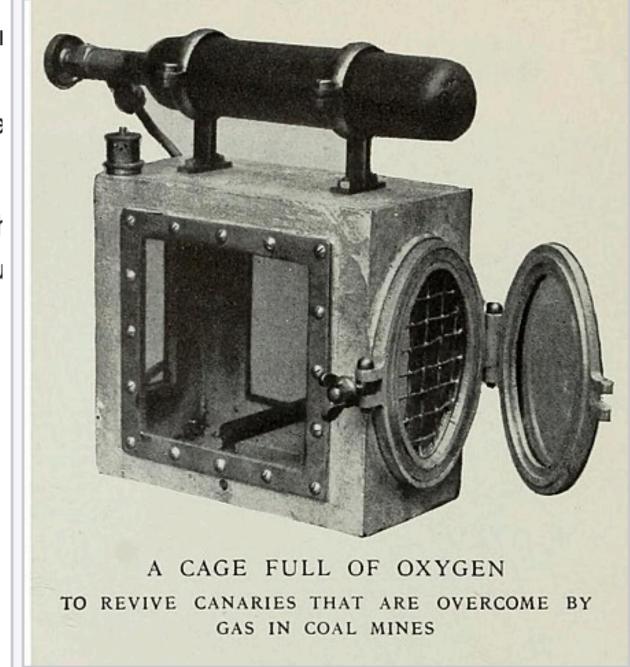
Stack Canaries

Miner's canary [edit]

suggested in 1895 by John Scott Haldane.^[16] Toxic gases such as carbon monoxide or asphyxiant gases such as methane^[17] in the mine would affect small warm-blooded animals before affecting the miners, since their respiratory exchange is more rapid than in humans. A mouse will be affected by carbon monoxide within a few minutes, while a human will have an interval of 20 times as long.^[18] Later, canaries were found to be more sensitive at a more effective indicator as they showed more visible signs of distress. Their use in mining is documented from around 1900.^[19] The birds were sometimes kept in carriers which had small oxygen bottles attached to revive the birds.^{[20][21]} The use of miners' canaries in British mines was phase out in 1986.^{[22][23]}

Mice were used as sentinel species for use in detecting carbon monoxide in British coal mining from around 1896,[15] after the idea had been

The phrase "canary in a coal mine" is frequently used to refer to a person or thing which serves as an early warning of a coming crisis. By analogy, the term "climate canary" is used to refer to a species (called an indicator species) that is affected by an environmental danger prior to other species, thu serving as an early warning system for the other species with regard to the danger.^[24]



Resuscitation cage with an oxygen cylinder serving as a handle used to revive a canary for multiple uses in detecting carbon monoxide pockets within mines

Stack Canaries

- Objectivo:
 - prevenir injeção de código detectando modificações à stack
- Ideia:
 - introduzir "canários" gerados dinamicamente entre variáveis locais e os valores do frame pointer e do endereço de retorno guardados na stack
 - verificar canário antes de utilizar o endereço de retorno
- Implementação: compilador modifica entrada e saída das funções

Exemplo

argv[1]
bbbbbbb
aaaaaaa
endereço de retorno
frame pointer
canário
deadbeef
buf[0-3]

Variantes

- Canário aleatório
 - No início da execução o programa escolhe um array de bytes aleatório
 - Esses bytes são colocados em todas as stack frames
 - Antes de retornar de uma função verifica-se a sua integridade
 - Se houver alguma alteração o programa termina
- Canário de terminação (usam '\0','\n',E0F em vez de bytes aleatorios)
 - As funções que manipulam strings irão sempre parar nestes valores

StackGuard

- Implementado pelo GCC (-fstack-protector-strong)
- Vantagens:
 - simples e fácil de colocar em prática
- Desvantagens:
 - overhead de espaço e performance
- Como fazer bypass aos canários?

Derrotando os canários

- Aproveitar apontadores:
 - se o código tem um apontador na stack e escreve para esse endereço outra variável local
 - um buffer overflow pode alterar ambas e escrever num ponto arbitrário em memória
- Apontadores para funções:
 - se um programa recebe um apontador para função como argumento
 - alterar esse apontador pode permitir saltar para endereço arbitrário antes de a função retornar
- Outra vulnerabilidade pode permitir "aprender" o canário, ou
- Se o canário for reutilizado muitas vezes, e.g., em cada fork, pode fazer-se um brute-force É "fácil" optimizar para um byte de cada vez: como?

Mitigações adicionais na stack

- Garantir que os buffers estão sempre junto ao canário
- Copiar sempre os argumentos da função para o topo da stack (abaixo dos buffers locais)
- O GCC também implementa estas proteções adicionais
- Shadow stack (suportado, e.g., Windows 10 2020):
 - stack redundante apenas para controlo (endereços frame e retorno)
 - antes de retornar da função verifica-se consistência
 - E.g., Intel Control Flow Enforcement Technology permite colocar shadow stack em páginas marcadas para escrita apenas por call/ret
- Outra possibilidade é ter os tipos de dados "perigosos" numa stack separada

Memory Tagging

- ARM Memory Tagging Extension:
 - suporte de hardware para criar tags (novas instruções)
 - permitem "ligar" apontadores às regiões para onde apontam
 - uma zona de memória alocada pode ter associada uma tag de 4 bits
 - o apontador que aponta para essa memória terá a mesma tag
 - compara-se tags no acesso: overflow => exceção
 - free altera tags: use after free => exceção
- Apresentado como suporte ao debugging e proteção extra contra overflows (adivinhar a tag)
- https://www.usenix.org/system/files/login/articles/login_summer19_03_serebryany.pdf

Control Flow Integrity

- Até agora olhámos para mitigações que se focam na memória.
- Uma alternativa é validar que a sequência de controlo está dentro de um conjunto de sequências válidas:
 - em tempo de compilação: determinar um conjunto válido de pontos de origem para cada destino válido
 - em tempo de execução: verificar consistência com essa informação
- Não é necessário proteger saltos diretos/chamadas estáticas que estão codificadas nas instruções => o atacante não consegue alterar o código, mas
- É necessário proteger todos os saltos/retornos cujos endereços são criados dinamicamente pelo programa

Control Flow Integrity

- Versão mais básica:
 - considerar apenas pontos de destino válidos as entradas de funções
 - confirmar que sempre que chegamos à entrada de uma função é resultado de um call
 - problema: não impede a chamada de funções numa sequência diferente, por exemplo, saltando por cima de um sistema de autenticação.
- Versões elaboradas implicam computar um grafo que define todos os saltos válidos
- Usando criptografia (veremos mais à frente):
 - sempre que um endereço é escrito algures na memória, guardar também um autenticador criptográfico
 - sempre que se usa o endereço verifica-se o autenticador
 - usa-se uma chave que não está em memória (um registo por exemplo)
- soluções e ataques têm sido muito discutidas no meio académico; implicam um overhead significativo

Control-Flow Integrity

- Implementações existem no Clang, MS Control Flow Guard, MS Return Flow Guard, Google Indirect Function-Call Checks, ...
- A shadow control stack, que referimos anteriormente, pode ser vista como parte do control-flow integrity
- As plataformas Intel permitem utilizar uma flag de HW para assinalar os entry points válidos para saltos, que têm de explicitamente desligar a flag
- O MS CFG functiona de forma parecida, mas utiliza uma tabela protegido por um hypervisor para gerir os endereços válidos

É possível mesmo assim?

- Apesar de todas estas mitigações os ataques continuam a aparecer
- São cada vez mais elaborados:
 - Trident exploit: permite remotamente desbloquear um iOS e instalar spyware
 - História interessante: detetado no mundo real e associado a empresa denominada NSO Group (ver 60 minutes)
 - Encadeia uma série de exploits de vulnerabilidades no browser e no kernel
- Conclusão: é essencial garantir que não existem "buracos" no tratamento de inputs potencialmente hostis



WHITEPAPER

Technical Analysis of the Pegasus Exploits on iOS

Trident/Pegasus

- 1. CVE-2016-4657: Memory Corruption in WebKit A vulnerability in Safari WebKit allows the attacker to compromise the device when the user clicks on a link.
- 2. CVE-2016-4655: Kernel Information Leak A kernel base mapping vulnerability that leaks information to the attacker that allows him to calculate the kernel's location in memory.
- 3. CVE-2016-4656: Kernel Memory corruption leads to Jailbreak 32 and 64 bit iOS kernel-level vulnerabilities that allow the attacker to silently jailbreak the device and install surveillance software.
- 4. The Pegasus Persistence Mechanism used for remaining on the device after compromise.



WHITEPAPE

Technical Analysis of the Pegasus Exploits on iOS

Trident/Pegasus

- Alguns detalhes:
 - vulnerabilidade use-after-free no GC do safari
 - é possível alterar o tamanho de array alocado para aceder a um espaço enorme de memória (read/write)
 - leituras => descobrir números mágicos + localizações
 - Descobrir objeto que vai ser compilado (JIT) => injetar código malicioso

Program Safety

Program Safety

- Conceito importante na área das linguagens de programação:
 - informalmente significa que a execução do programa permanece dentro do âmbito especificado pela semântica da linguagem
 - Exemplo: a linguagem descreve o que deve acontecer quando escrevemos e lemos de uma região válida de memória, mas é omissa nos outros casos
 - um programa que utiliza uma zoná inválida de memória é unsafe
 - Exemplo: a semântica da linguagem indica que os cálculos sobre inteiros de precisão limitada apenas são consistentes com $\mathbb Z$ dentro de uma determinada gama
 - um programa que assume consistência com $\mathbb Z$ fora dessa gama é unsafe

Memory Safety

- Nas operações de memória existem diversos tipos de operações unsafe:
 - em geral todas elas aparecem como tendo resultados "undefined" na semântica de linguagens como o C
 - Read: ler de zona inválida
 - Write: escrever em zona inválida
 - Execute: interpretar como instruções executáveis dados inválidos
- Safety espacial: validade depende apenas da localização
- Safety temporal: validade depende do tempo de vida do objeto/variável

Garantir Program Safety

- Algumas linguagens de programação oferecem mais automação do que outras para garantir safety:
 - Linguagens strongly typed como Java ou Haskell verificam um conjunto muito alargado de condições em tempo de compilação:
 - os tipos de dados são compatíveis com as operações que sobre eles são realizadas (arrays)
 - Outras linguagens como Python são weakly typed, mas verificam type safety na execução
 - Linguagens interpretadas como Java ou Python detectam problemas de safety na execução
 - acessos errados a memória/containers originam exceções => controlo passa a DoS
 - O Rust inclui um conjunto de checks estáticos e dinâmicos para garantir safety, etc.

Verificação de Programas

- Mesmo em linguagens como o C ou assembly é possível ter garantias de safety:
 - existem ferramentas que nos permitem verificar essas propriedades
 - algumas são dinâmicas/incompletas, mas automáticas: valgrind, fuzzing
 - outras são completas e baseadas em matemática/lógica:
 - os programas são anotados (comentados) com meta-informação que descreve as propriedades funcionais (e.g., o que é tocado em memória)
 - é necessário construir uma prova matemática de que se verificam (Frama-C, etc.)
 - aqui pode haver diferentes níveis de automação no auxílio da construção de uma prova

Conclusão



Porque existem vulnerabilidades?

- Os programadores fazem erros
 - é preciso utilizar ferramentas para os ajudar a evitar erros
- Os programadores muitas vezes não têm noção das implicações de um erro => formação! (esta UC!)
- As linguagens de programação não são desenhadas com o objetivo de garantir segurança:
 - ainda assim, umas linguagens são melhores que outras, e oferecem validação estática de algumas propriedades de safety e run-time checks de outras
 - Java, Python, Rust, etc.

Defesa em profundidade

- Existem mecanismos de mitigação a diversos níveis
 - processador, compilador, linguagem de programação, ...
 - verificação automática de bounds (e.g., Rust, Java, Python)
 - randomização de endereços, W^X, etc.
 - Control-Flow Integrity
- Mas podem falhar todos e não temos fallback
 - Pior: continuamos sujeitos a ataques por DoS (exceções, crash, etc.)
 - Como se recupera de falhas? Repomos o estado? => Pode permitir brute-force